



# APLICACIONES DE DATA SCIENCE



¿En qué consiste un  
modelo de clasificación?



## Logro Unidad 2

El estudiante podrá utilizar las habilidades que necesita para aplicar la ciencia de datos a las diferentes tareas de la minería de textos.



# Contenido 4

## Clasificador Bayesiano



## 1. Motivación

# Clasificación de Texto



Dado un conjunto finito de **categorías** poder asignar documentos a esas categorías.

- Clasificación Bayesiana



## 1. Motivación

**¿Dónde usamos clasificación de texto?**



## 1. Motivación

### ¿Dónde usamos clasificación de texto?

- 1 Filtro de correo electrónico, por la cantidad de SPAM que nos llega es importante tener un filtro automático de SPAM.



## 1. Motivación

# Is this spam?

**Subject:** Important notice!

**From:** Stanford University <newsforum@stanford.edu>

**Date:** October 28, 2011 12:34:16 PM PDT

**To:** undisclosed-recipients;;

---

Greats News!

You can now access the latest news by using the link below to login to Stanford University News Forum.

<http://www.123contactform.com/contact-form-StanfordNew1-236335.html>

Click on the above link to login for more information about this new exciting forum. You can also copy the above link to your browser bar and login for more information about the new services.

© Stanford University. All Rights Reserved.





## 1. Motivación

### ¿Cuál es la idea?

Poder **entrenar** este Filtro de correo electrónico. Para ello, se debe identificar manualmente si el correo recibido es SPAM o no SPAM, para que el algoritmo de machine learning sea capaz de reconocer este patrón y después se pueda aplicar a nuevos documentos.



## 1. Motivación

### ¿Dónde usamos clasificación de texto?

## 2 Identificar el genero de un autor.

### Male or female author?

1. By 1925 present-day Vietnam was divided into three parts under French colonial rule. The southern region embracing Saigon and the Mekong delta was the colony of Cochin-China; the central area with its imperial capital at Hue was the protectorate of Annam...
2. Clara never failed to be astonished by the extraordinary felicity of her own name. She found it hard to trust herself to the mercy of fate, which had managed over the years to convert her greatest shame into one of her greatest assets...



## 1. Motivación

### ¿Cuál es la idea?

Poder encontrar un patrón en el texto que nos permita generalizar más allá de lo que vemos en nuestro CORPUS de entrenamiento.







## 1. Motivación

**¿Dónde usamos clasificación de texto?**

### **3** Clasificación de sentimientos

**Positive or negative movie review?**

-  • unbelievably disappointing
-  • Full of zany characters and richly applied satire, and some great plot twists
-  • this is the greatest screwball comedy ever filmed
-  • It was pathetic. The worst part about it was the boxing scenes.

- Clasificación Bayesiana



## 1. Motivación

**¿Dónde usamos clasificación de texto?**

**4** Clasificación de tópicos (categorías de documentos)



## 1. Motivación


# What is the subject of this article?

## MEDLINE Article



## MeSH Subject Category Hierarchy


- Antagonists and Inhibitors
- Blood Supply
- Chemistry
- Drug Therapy
- Embryology
- Epidemiology
- ...





## 1. Motivación

# Clasificación de Texto



En conclusión es una tarea que se utiliza mucho!



## 1. Motivación

# Clasificación de Texto

Definición formal:

➤ INPUT:

- Un documento  $d$
- Un conjunto fijado de clases  $C = \{c_1, c_2, \dots, c_j\}$

➤ OUTPUT:

- Predecir la clase  $c \in C$  a la cual pertenece el documento  $d$

Modelo  
Tradicional





## 1. Motivación

# Clasificación de Texto

Definición formal:

➤ INPUT:

- Un documento  $d$
- Un conjunto fijado de clases  $C = \{c_1, c_2, \dots, c_j\}$

➤ OUTPUT:

- Predecir la clase  $c \in C$  a la cual pertenece el documento  $d$

Modelo  
Probabilístico



## 1. Motivación

# Clasificación de Texto

Definición formal:

➤ INPUT:

- Un documento  $d$
- Un conjunto fijado de clases  $C = \{c_1, c_2, \dots, c_j\}$

➤ OUTPUT:

- Predecir la clase  $c \in C$  a la cual pertenece el documento  $d$
- Probabilidad de pertenencia para cada clase, y la clase con mayor probabilidad será escogida.

Modelo  
Probabilístico



## 1. Motivación

# Clasificación de Texto

Definición formal:

➤ INPUT:

- Un documento  $\mathbf{d}$
- Un conjunto fijado de clases  $\mathbf{C} = \{c_1, c_2, \dots, c_j\}$
- Un conjunto de entrenamiento con  $m$  documentos etiquetados  $(\mathbf{d}_1, c_1), (\mathbf{d}_2, c_2), \dots, (\mathbf{d}_m, c_m)$ .

➤ OUTPUT:

- Un clasificador  $f: \mathbf{d} \rightarrow \mathbf{c}$ . En donde  $\mathbf{d}$  va ser un vector y vamos a obtener la probabilidad de las clases.

Modelo  
Aprendizaje  
Supervisado

- Clasificación Bayesiana



## **2. Algoritmo Naive Bayes – Clasificación Bayesiana**



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ Axiomas de probabilidad:

Sea  $P$  una función que asocia a cada evento  $E$  de  $S$  un número real:

1. Para algún evento  $E$ ,  $0 \leq P(E) \leq 1$

2.  $P(S) = 1$

3.  $P(A \cup B) = P(A) + P(B)$ , si  $A \cap B = \emptyset$

En general: para alguna secuencia de eventos mutuamente excluyentes

$E_n, n \geq 1$ , tal que  $E_i \cap E_j = \emptyset \rightarrow P(\bigcup_{n=1}^{\infty} E_n) = \sum_{n=1}^{\infty} P(E_n)$

$S = \{1, 2, 3, 4, 5, 6\}$

$A = \{2, 4, 6\}$

$B = \{1, 3, 5\}$

$P(A \cap B) = 0 \Rightarrow A$  y  $B$  son eventos disjuntos o mutuamente excluyentes.



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ Probabilidad condicional:

La probabilidad condicional se refiere a hallar la probabilidad de un evento conociendo cierta información (condición) y se define como:

$$P \left( \frac{A}{B} \right) = \frac{P(A \cap B)}{P(B)}$$

Representa la probabilidad condicional de A, dado que ocurrió el evento B.

Donde  $P(B) > 0$ .



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ Ejemplo:

Hace unos años, la mayoría de las estaciones de servicio vendían tres tipos de gasolina: 84 octanos, 95 octanos y 97 octanos. Con frecuencia, alguna de cada está enriquecida con un aditivo. La tabla siguiente ilustra los porcentajes de clientes que prefieren cada tipo.

	90 octanos (B)	95 octanos (C)	97 octanos (D)	Total
Con Aditivo (A)	0.05	0.10	0.05	0.20
Sin Aditivo (A')	0.15	0.40	0.25	0.80
Total	0.20	0.50	0.30	1.00

- ¿Cuál es la probabilidad de que haya comprado gasolina con aditivo o no sea de 95 octanos?
- Si el cliente no compró gasolina de 95 octanos, ¿cuál es la probabilidad de que compre gasolina de 97 octanos?
- Si el cliente no compró gasolina de 90 octanos, ¿cuál es la probabilidad de que haya comprado gasolina sin aditivo?



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

❖ Solución:

	90 octanos (B)	95 octanos (C)	97 octanos (D)	Total
Con Aditivo (A)	0.05	0.10	0.05	0.20
Sin Aditivo (A')	0.15	0.40	0.25	0.80
Total	0.20	0.50	0.30	1.00

a. ¿Cuál es la probabilidad de que haya comprado gasolina con aditivo o no sea de 95 octanos?

$$P(A \cup C') = P(A) + P(C') - P(A \cap C') = 0,20 + 0,50 - (0,05 + 0,05) = 0,60$$

b. Si el cliente no compró gasolina de 95 octanos, ¿cuál es la probabilidad de que compre gasolina de 97 octanos?

$$P(D/C') = \frac{P(D \cap C')}{P(C')} = \frac{0,30}{0,50} = 0,60$$

c. Si el cliente no compró gasolina de 90 octanos, ¿cuál es la probabilidad de que haya comprado gasolina sin aditivo?

$$P(A'/B') = \frac{P(A' \cap B')}{P(B')} = \frac{0,65}{0,80} = 0,8125$$





## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

- ❖ Esta basado en la BOLSA DE PALABRAS (modelos vectorial).
- ❖ Es un método de clasificación basado en el **TEOREMA de BAYES**.

*Para dos sucesos A y B,*

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

- ❖ Esta basado en la BOLSA DE PALABRAS (modelos vectorial).
- ❖ Es un método de clasificación basado en el **TEOREMA de BAYES**.

*Para dos sucesos A y B,*

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$p(A|B)$ : Probabilidad a posteriori

$p(B|A)$ : Función de verosimilitud

$p(A)$ : Probabilidad a priori



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### The Bag of Words Representation

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!



it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### The bag of words representation

**f**(

seen	2
sweet	1
whimsical	1
recommend	1
happy	1
...	...

) = **C**



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

- ❖ Esta basado en la BOLSA DE PALABRAS (modelos vectorial).
- ❖ Es un método de clasificación basado en el **TEOREMA de BAYES**.

*Para dos sucesos A y B,*

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$p(A|B)$ : Probabilidad a posteriori

$p(B|A)$ : Función de verosimilitud

$p(A)$ : Probabilidad a priori

- Clasificación Bayesiana



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ **TEOREMA de BAYES**

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ **TEOREMA de BAYES**

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$

❖ Ejemplo:

$$P(A=3 | B = \text{impar}) = \frac{P(B=\text{impar} | A=3) * P(A=3)}{P(B=\text{impar})}$$



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ **TEOREMA de BAYES**

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$

❖ Ejemplo:

$$P(A=3 | B = \text{impar}) = \frac{P(B=\text{impar} | A=3) * P(A=3)}{P(B=\text{impar})}$$

$$P(A=3 | B = \text{impar}) = \frac{(1) * (1/6)}{1/2} = 1/3$$






## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

❖ **TEOREMA de BAYES**

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$



Vamos a utilizar el teorema de Bayes para clasificar documentos probabilísticamente.

- Para un documento **d** y para una clase **c**

$$P(c | d) = \frac{P(d | c) * P(c)}{P(d)}$$



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ TEOREMA de BAYES

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$


$$c_{MAP} = \operatorname{argmax}_{c \in C} P(c | d)$$

MAP is “maximum a posteriori” = most likely class

$$= \operatorname{argmax}_{c \in C} \frac{P(d | c)P(c)}{P(d)}$$

Bayes Rule


$$= \operatorname{argmax}_{c \in C} P(d | c)P(c)$$



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

❖ **TEOREMA de BAYES**

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$



$$c_{MAP} = \operatorname{argmax}_{c \in C} P(d | c) P(c)$$

$$= \operatorname{argmax}_{c \in C} P(x_1, x_2, \dots, x_n | c) P(c)$$


Document d  
represented as  
features  
x1..xn



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

### ❖ TEOREMA de BAYES

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$



$$P(x_1, x_2, \dots, x_n | c)$$

- **Bag of Words assumption:** Assume position doesn't matter
- **Conditional Independence:** Assume the feature probabilities  $P(x_i | c_j)$  are independent given the class  $c$ .


$$P(x_1, \dots, x_n | c) = P(x_1 | c) \cdot P(x_2 | c) \cdot P(x_3 | c) \cdot \dots \cdot P(x_n | c)$$



## 2. Algoritmo Naive Bayes – Clasificación Bayesiana

❖ **TEOREMA de BAYES**

$$P(A | B) = \frac{P(B | A) * P(A)}{P(B)}$$



$$c_{MAP} = \operatorname{argmax}_{c \in C} P(x_1, x_2, \dots, x_n | c) P(c)$$

$$c_{NB} = \operatorname{argmax}_{c \in C} P(c_j) \prod_{x \in X} P(x | c)$$

- Clasificación Bayesiana



### **3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana**



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

La regla de Bayes establece que, si tenemos una hipótesis “H” sustentada para una evidencia “E”, entonces:

$$p(H|E) = \frac{p(E|H)p(H)}{p(E)}$$

$p(H|E)$ : Probabilidad a posteriori

$p(E|H)$ : Función de verosimilitud

$p(H)$ : Probabilidad a priori



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

Ejemplo: Una compañía de seguros dispone de los siguientes datos sobre sus clientes, clasificados en buenos y malos clientes:

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No





### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

- La hipótesis “H” es que “buen cliente” sea Si o No.
- La evidencia E es una combinación de los valores de los atributos: edad, hijos, practica deporte y salario del dato nuevo, por lo que su probabilidad se obtiene multiplicando las probabilidades de estos valores:

$$p(si|E) = \frac{[p(edad|si).p(hijos|si).p(practica\ deporte|si).p(salario|si)].p(si)}{p(E)}$$

$$p(no|E) = \frac{[p(edad|no).p(hijos|no).p(practica\ deporte|no).p(salario|no)].p(no)}{p(E)}$$



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

Tenemos un nuevo caso con las siguientes características:

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
11	Mayor	No	No	Medio	?

$$p(si|E) = [p(edad|si).p(hijos|si).p(practica\ deporte|si).p(salario|si)].p(si)$$

$$p(no|E) = [p(edad|no).p(hijos|no).p(practica\ deporte|no).p(salario|no)].p(no)$$



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(\text{buen cliente} = \text{si}) = 7 / 10$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(\text{edad} = \text{mayor} | \text{buen cliente} = \text{si}) = 3 / 7$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(hijos = no | buen\ cliente = si) = 2 / 7$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(\text{practica deporte} = \text{no} | \text{buen cliente} = \text{si}) = 4 / 7$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(\text{salario} = \text{medio} | \text{buen cliente} = \text{si}) = 3 / 7$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(\text{buen cliente} = \text{no}) = 3 / 10$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No





### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(edad = mayor | buen\ cliente = no) = 1 / 3$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(hijos = no | buen cliente = no) = 2 / 3$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(\text{practica deporte} = \text{no} | \text{buen cliente} = \text{no}) = 2 / 3$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

$$p(\text{salario} = \text{medio} | \text{buen cliente} = \text{no}) = 2 / 3$$

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
1	Joven	Si	No	Alto	Si
2	Joven	No	No	Medio	No
3	Joven	Si	Si	Medio	No
4	Joven	Si	No	Bajo	Si
5	Mayor	Si	No	Bajo	Si
6	Mayor	No	Si	Medio	Si
7	Joven	No	Si	Medio	Si
8	Joven	Si	Si	Alto	Si
9	Mayor	Si	No	Medio	Si
10	Mayor	No	No	Bajo	No



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

Tenemos un nuevo caso con las siguientes características:

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
11	Mayor	No	No	Medio	?



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

- Las probabilidades se pueden determinar de la siguiente manera:

$$p(si) = 7 / 10$$

$$p(no) = 3 / 10$$

$$p(edad = mayor|si) = 3 / 7$$

$$p(edad = mayor|no) = 1 / 3$$

$$p(hijos = no|si) = 2 / 7$$

$$p(hijos = no|no) = 2 / 3$$

$$p(practica deporte = no|si) = 4 / 7$$

$$p(practica deporte = no|no) = 2 / 3$$

$$p(salario = medio|si) = 3 / 7$$

$$p(salario = medio|no) = 2 / 3$$

$$p(si|E) = 0.0210$$

$$p(no|E) = 0.0296$$



### 3. Ejemplo de Algoritmo Naive Bayes – Clasificación Bayesiana

Tenemos un nuevo caso con las siguientes características:

ID	Edad	Hijos	Practica Deporte	Salario	Buen Cliente
12	Joven	Si	Si	Alto	No



CIERRE





Probabilidad

Teorema de  
Bayes

Clasificación de  
texto



# CONSULTAS

[pcsirife@upc.edu.pe](mailto:pcsirife@upc.edu.pe)